Algorytmy ewolucyjne

Neuroewolucja

Projekt zaliczeniowy

Michał Maras, Michał Kępa

11 lutego 2021

Spis treści

1. Wprowadzenie
2. Środowiska
3. Algorytmy

Wprowadzenie

Cel

Celem projektu jest wykorzystanie algorytmów ewolucyjnych jako sposobu trenowania sieci neuronowych w problemach uczenia przez wzmacnianie.

Rozważone zostały następujące problemy:

- CartPole – Open AI Gym Benchmark
- gra Pong – Open AI Atari Gym oraz własna implementacja
- gra 2048 – własna implementacja
- gra CarRacing – własna implementacja
- gra Beamrider – Open AI Atari Gym

Uczenie przez wzmacnianie

Uczenie przez wzmacnianie
(ang. *Reinforcement Learning*) – rodzaj uczenia maszynowego, którego zadaniem jest interakcja ze środowiskiem. W uczeniu przez wzmacnianie celem modelu jest wykonywanie odpowiednich akcji na podstawie danych ze środowiska, za które agent otrzyma jak największą nagrodę.

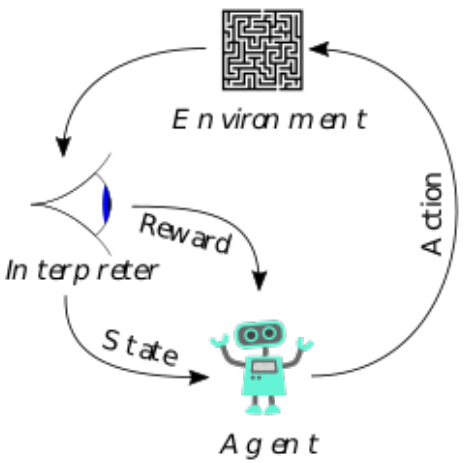

Środowiska

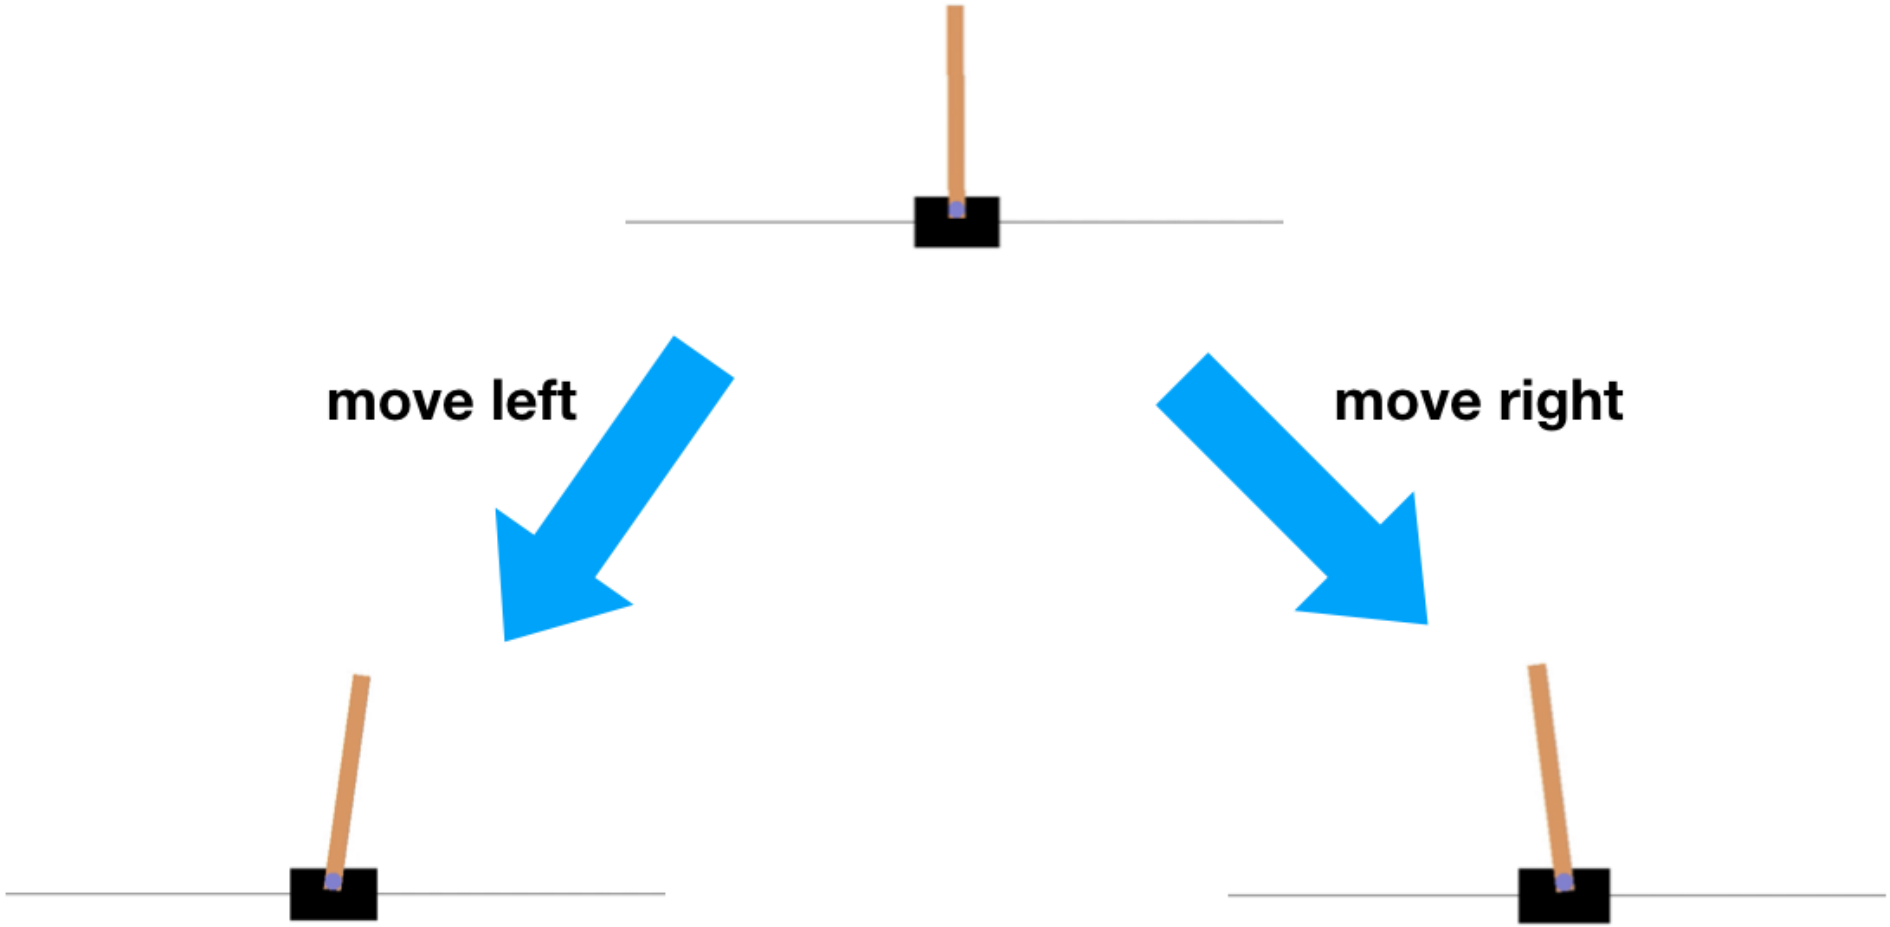

CartPole

CartPole

Problem

Środowisko zawiera wózek i przymocowany do niego maszt. W stanie początkowym maszt jest położony prawie pionowo, a w wyniku oddziaływania grawitacji zaczyna coraz bardziej przechylać się na jedną stronę. Agent ma za zadanie przesuwać wózek w prawo lub lewo z odpowiednią siłą, aby utrzymać słupek jak najdłużej w pionie. Gdy masz się przewróci – gra się kończy.

Obserwacja

Agent otrzymuje informacje o pozycji oraz prędkości wózka i masztu.

Nagroda

Nagroda za grę zależy od długości jej trwania. Dodatkowo, w każdej klatce naliczna jest kara zależna od odległości wózka od środka planszy oraz odchylenia masztu od pionu.

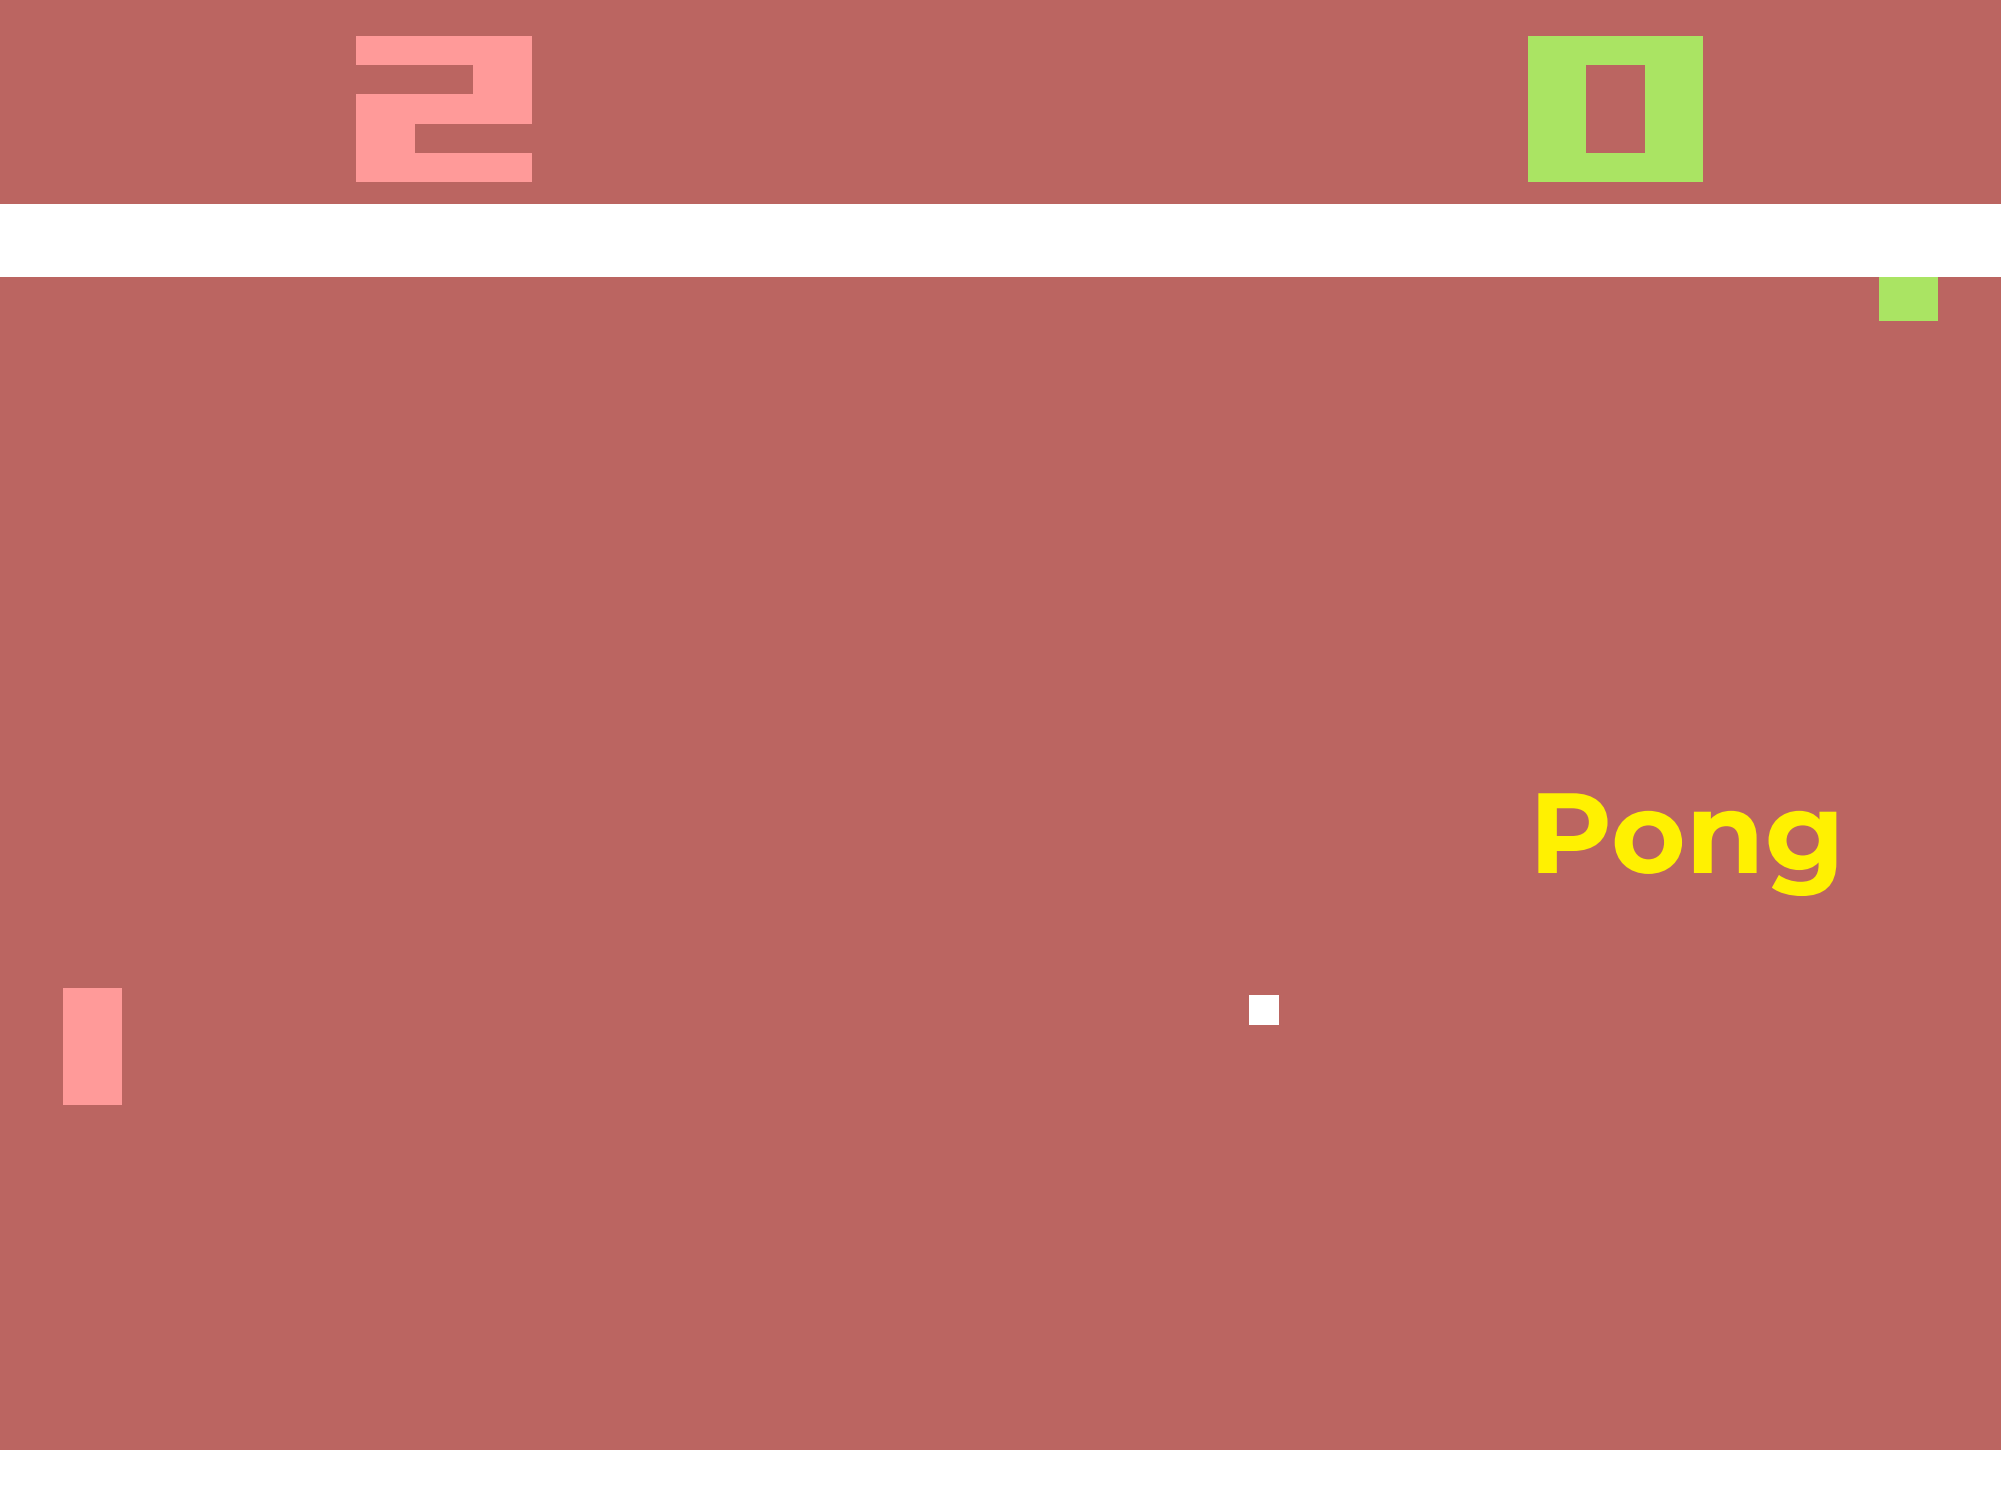
2
0
Pong

Pong

Problem

Typowa implentacja gry pong: jest dwóch graczy, którzy sterują paletkami i odbijają piłeczkę. W przypadku własnej implementacji gra trwała 10 rund, a w wersji OpenAI do 21 wygranych rund.

Obserwacja

Agent dostaje stan złożony z pozycji paletek oraz pozycji i prędkości piłki. Inną wersją obserwacji był stan pamięci RAM emulatora (128 bajtów)

Nagroda

Nagroda to wynik gry (liczba zdobytych punktów) z bonusem za wygraną, powiększona (w przypadku przegranej) lub pomniejszona (w przypadku wygranej) o czas trwania gry. Sprawdzona została też modyfikacja, gdzie wynik zależy od odległości paletki od piłki w momencie zdobycia lub straty punktu.

2048

2048

Problem

Implementacja podobna do oryginalnej wersji, ale w przypadku wykonania niedozowolnego ruchu gra natychmiast się kończy. Gracz ma możliwość przesunąć wszystkie bloczki na planszy w określonym kierunku. Gdy dwa bloczki z takim samym numerem się spotkają, łączą się w jeden bloczek o dwa razy większej wartości.

Obserwacja

Agent dostaje stan złożony z logarytmów wartości kolejnych kafelków na planszy (lub 0 w przypadku pustego pola).

Nagroda

Nagroda to suma wartości kafelków na planszy.

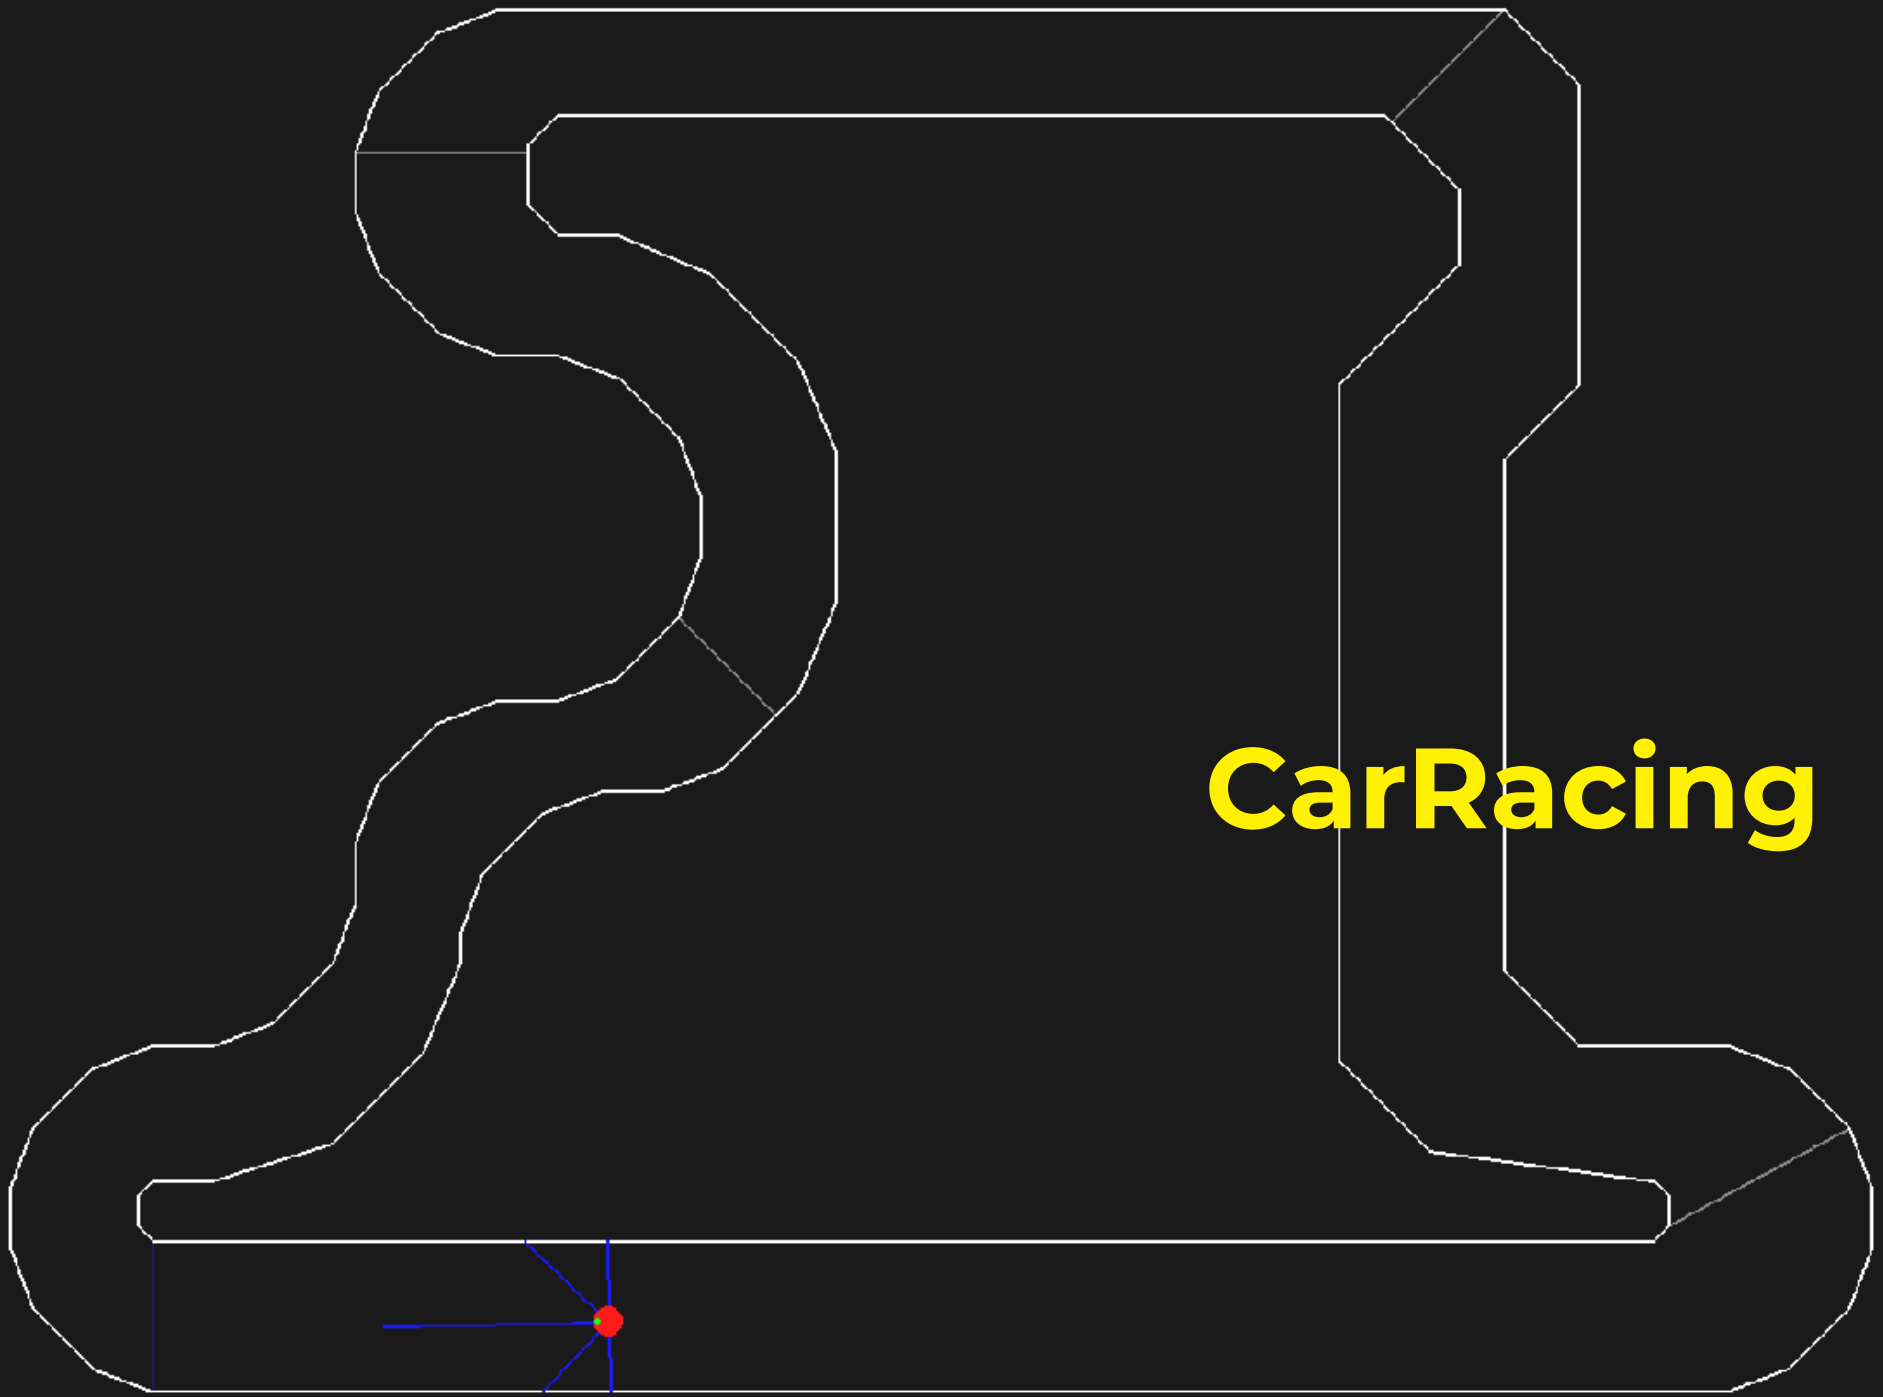
CarRacing

CarRacing

Problem

Środowisko składa się z samochodu, toru oraz listy punktów kontrolnych, przez które kolejno musi przejechać agent. Gdy gracz wjedzie w ścianę – przegrywa.

Obserwacja

Agent dostaje stan złożony z odległości do najbliższej przeszkody w pięciu różnych kierunkach.

Nagroda

Nagroda to długość przejechanej trasy.


000000
SECTOR 00
Beamrider
ACTIVISION

Beamrider

Problem

Środowiskiem jest symulacja gry Beamrider z konsoli Atari 2600.

Obserwacja

Agent dostaje stan pamięci RAM emulatora (128 bajtów).

Nagroda

Liczba punktów zdobytych w grze, która zależała od długości gry, liczby pokonanych przeciwników i liczby zakończonych etapów.

Algorytmy

Do neuroewolucji zastosowaliśmy następujące algorytmy:

- CMA-ES,
- NEAT,
- LM-MA-ES.

Rezultaty

CartPole NEAT

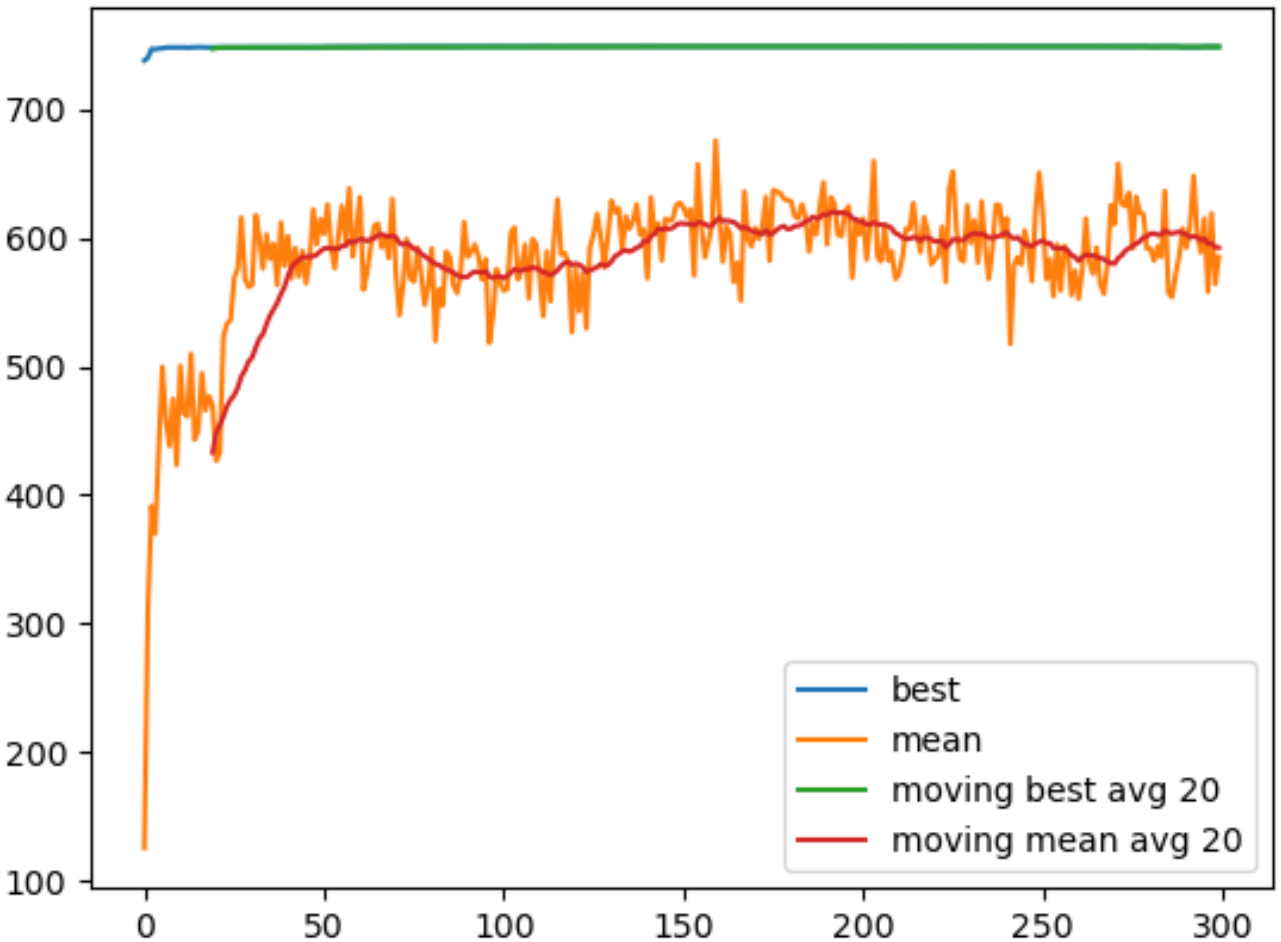

CartPole CMA-ES

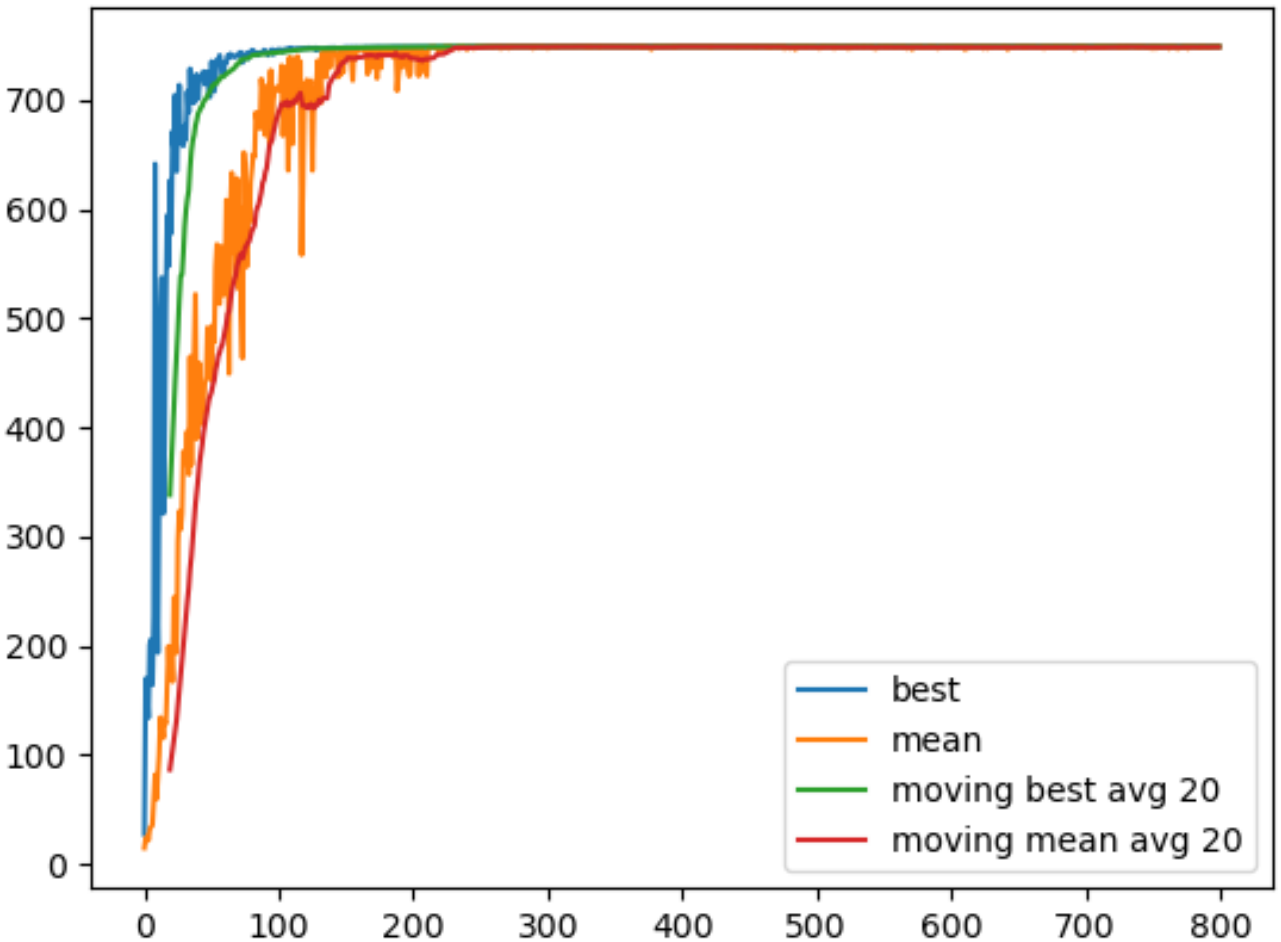

Pong CMA-ES

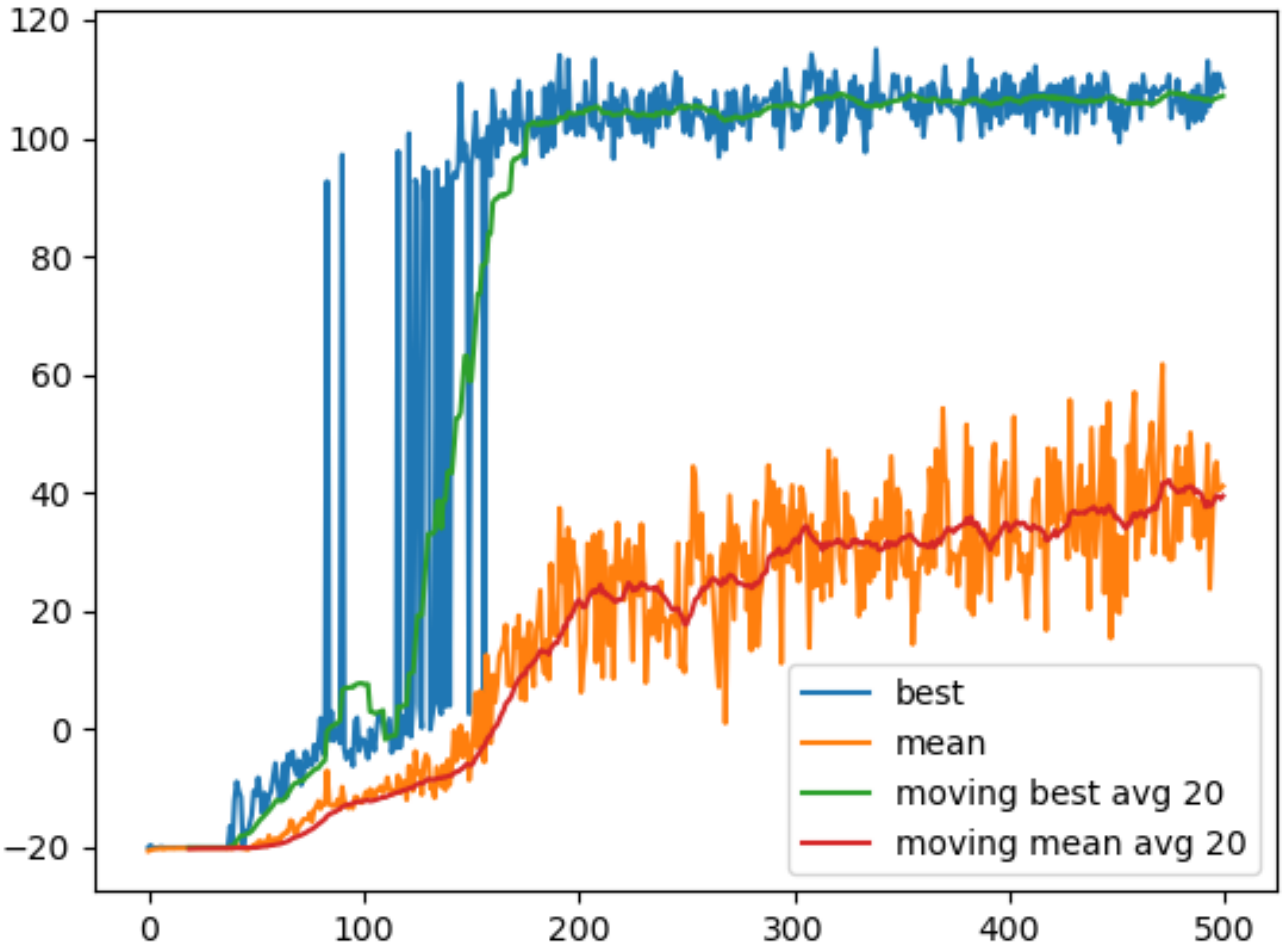
120
100
80
60
40
20
0
−20
0
100
200
300
400
500
best
mean
moving best avg 20
moving mean avg 20

Pong NEAT

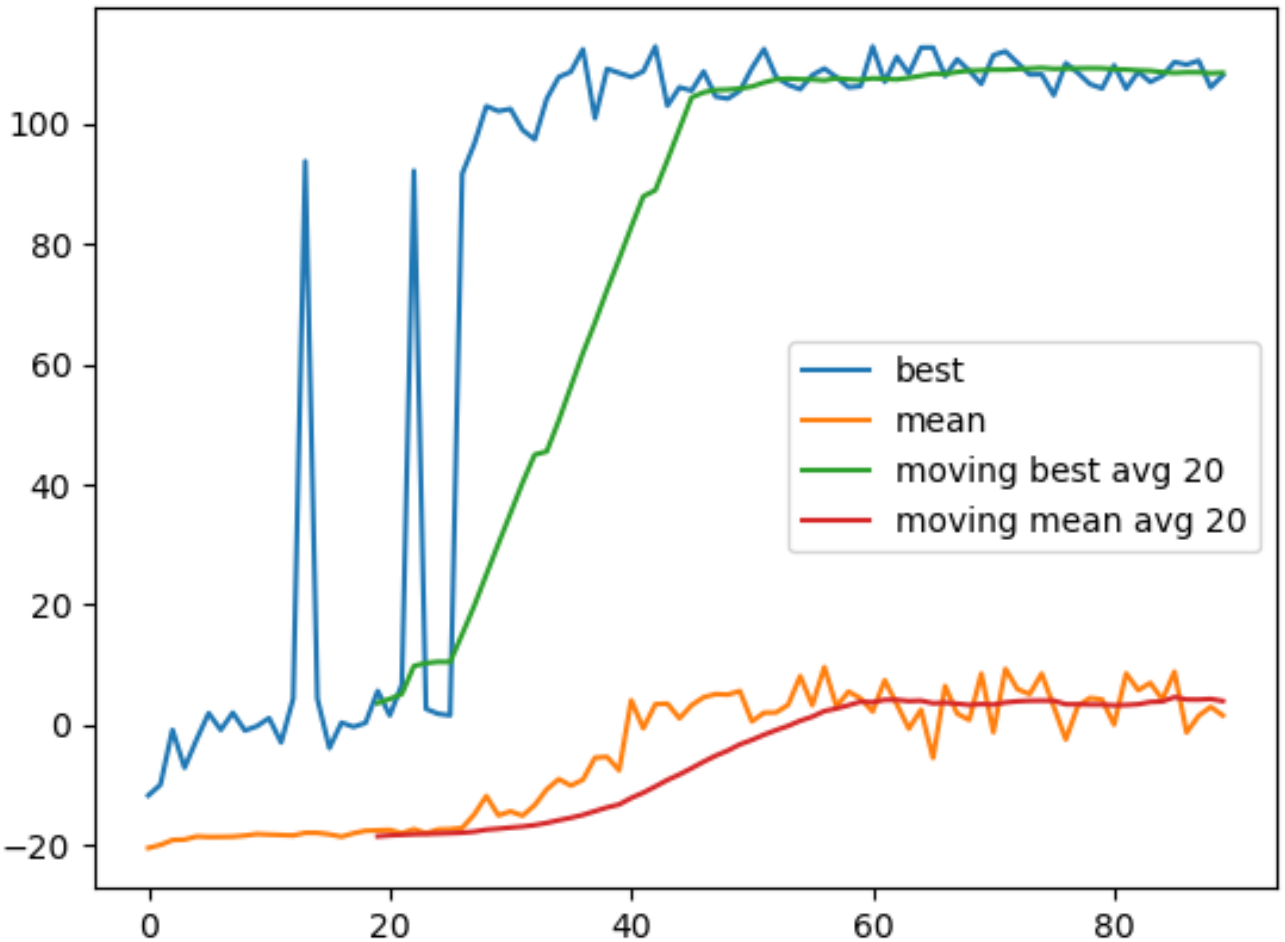
100
80
60
40
20
0
−20
0
20
40
60
80
best
mean
moving best avg 20
moving mean avg 20

Pong LM-MA-ES (RAM)

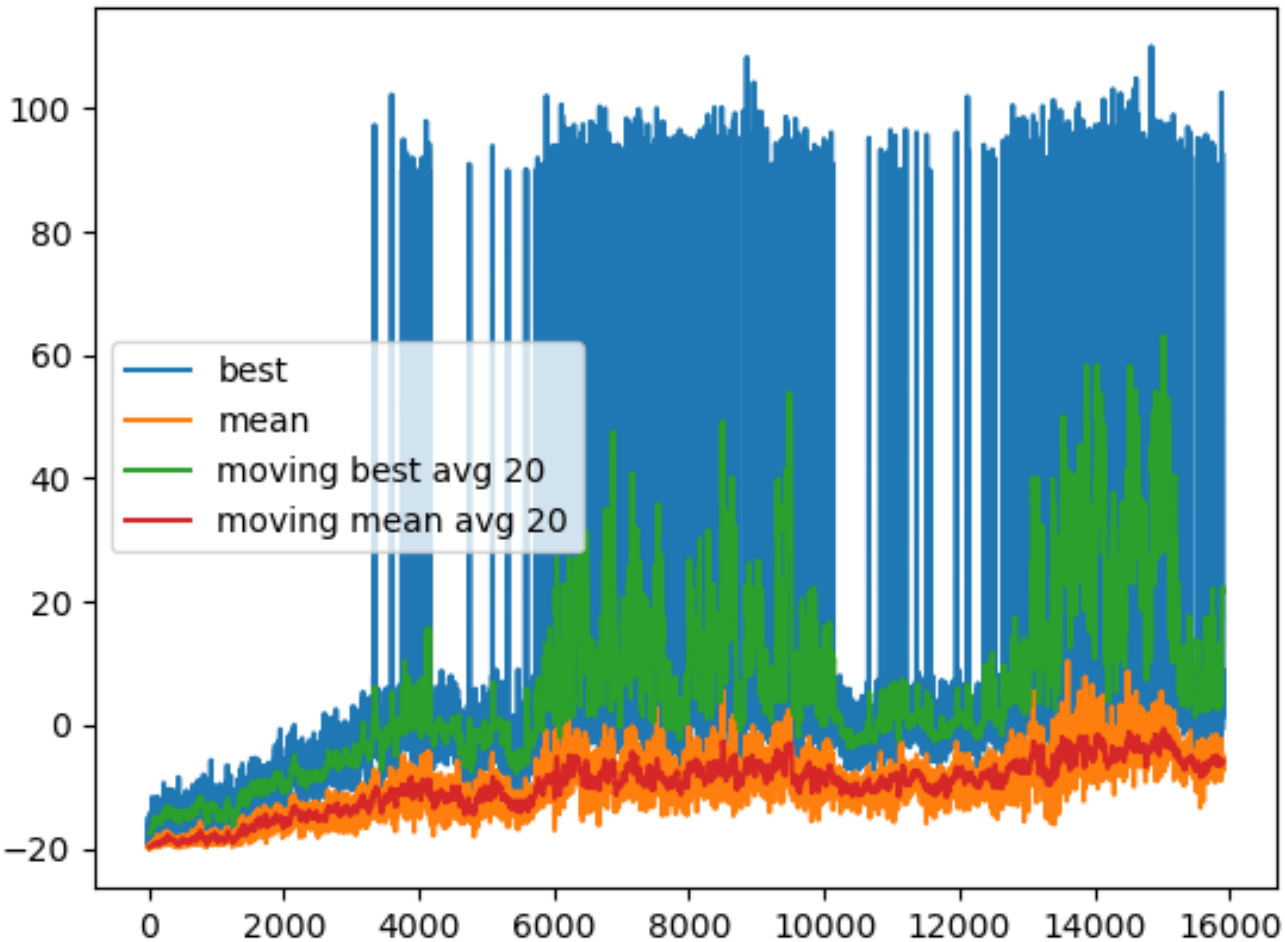

Pong NEAT (RAM)

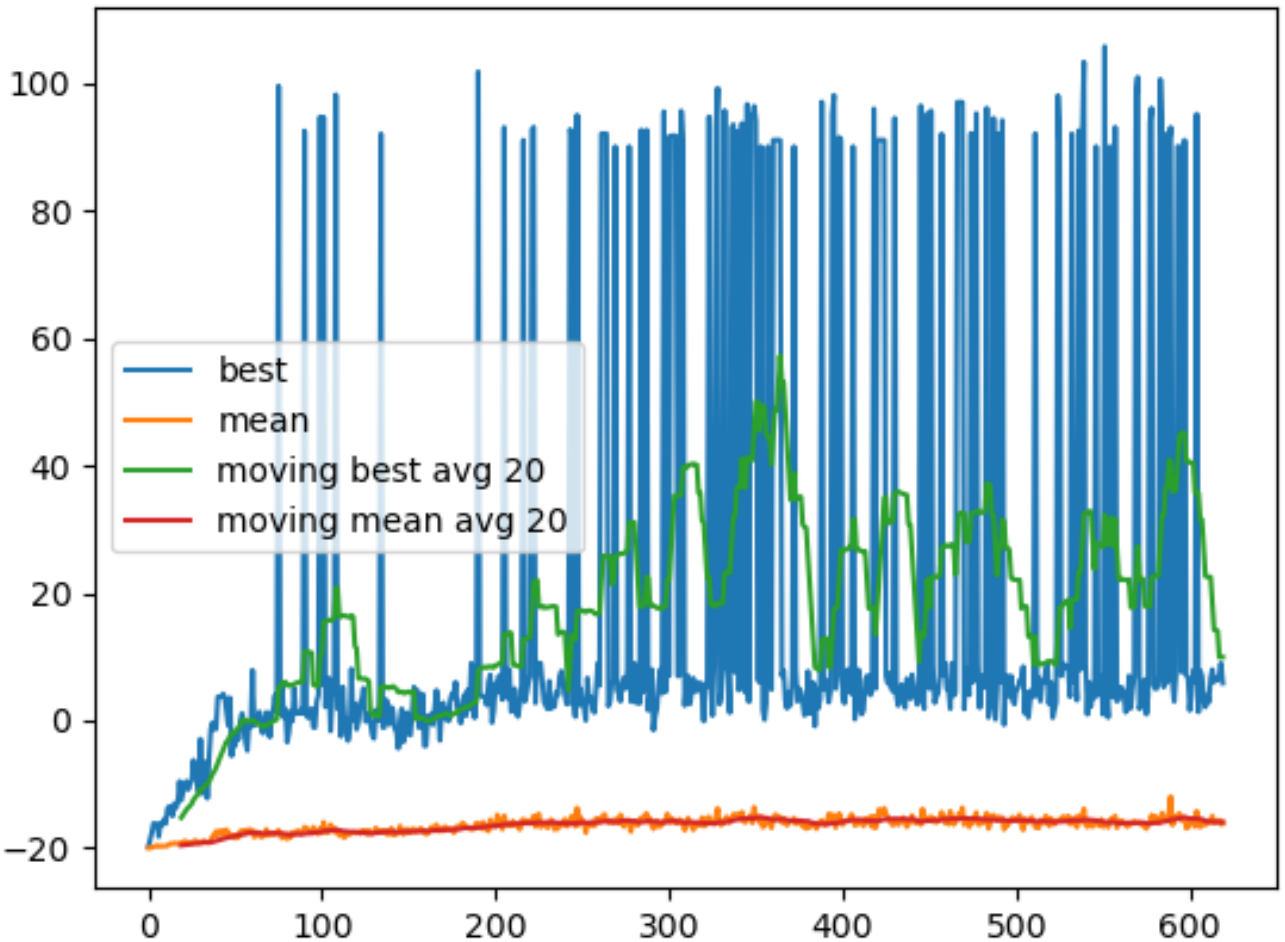

CarRacing NEAT

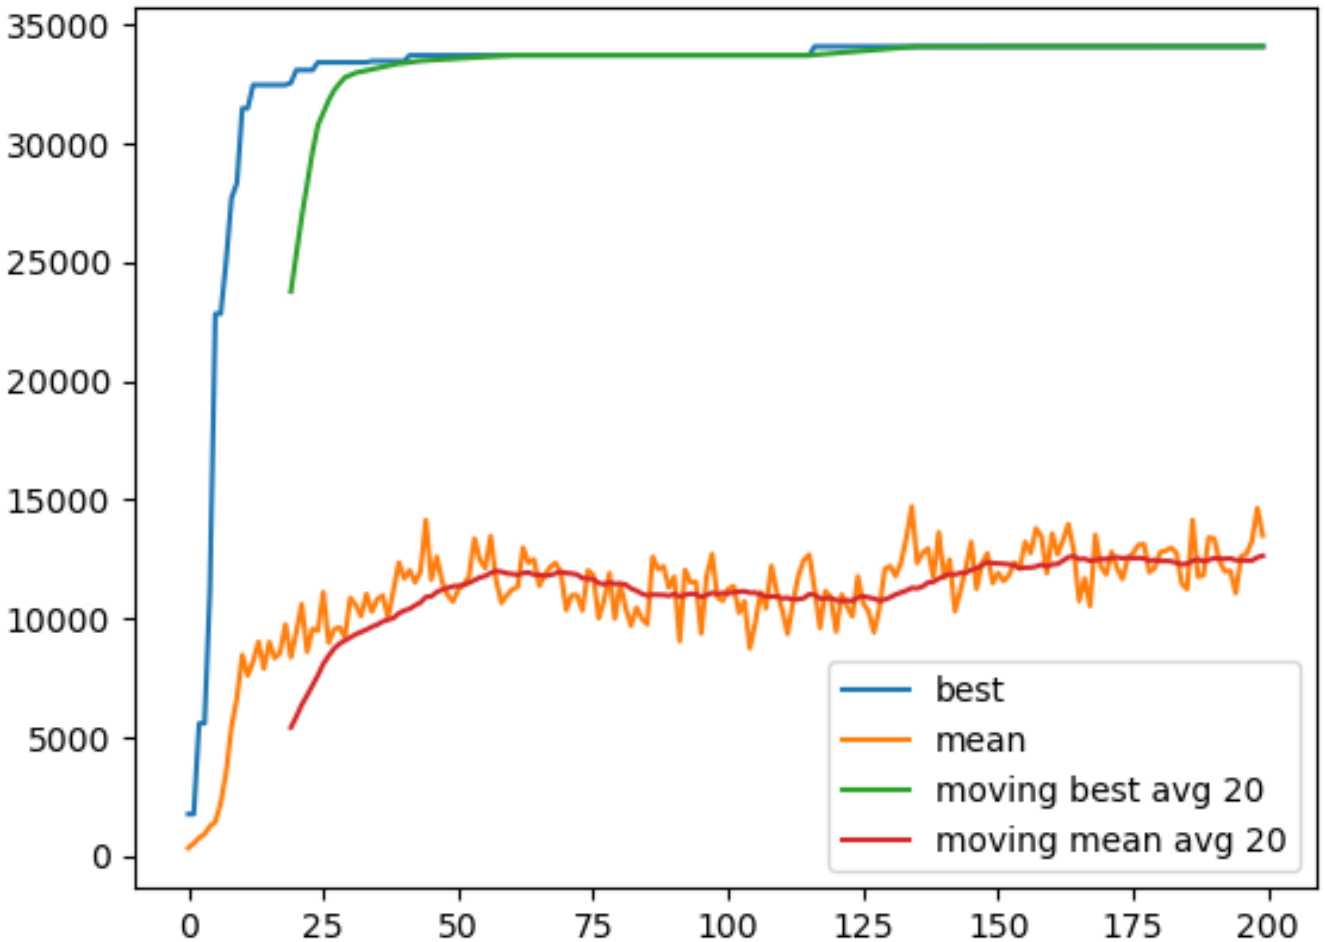

CarRacing CMA-ES

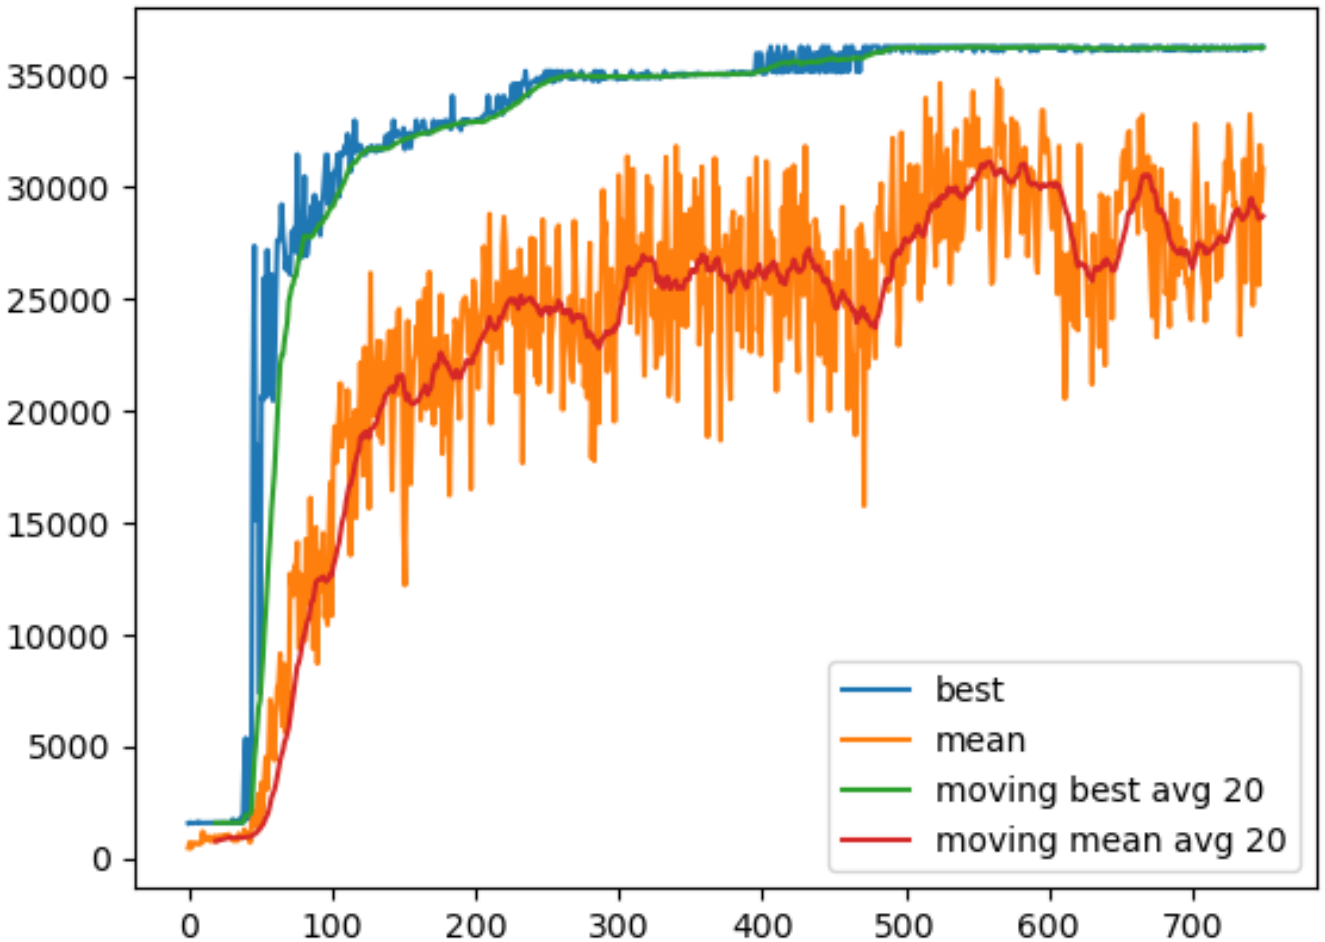

2048 NEAT

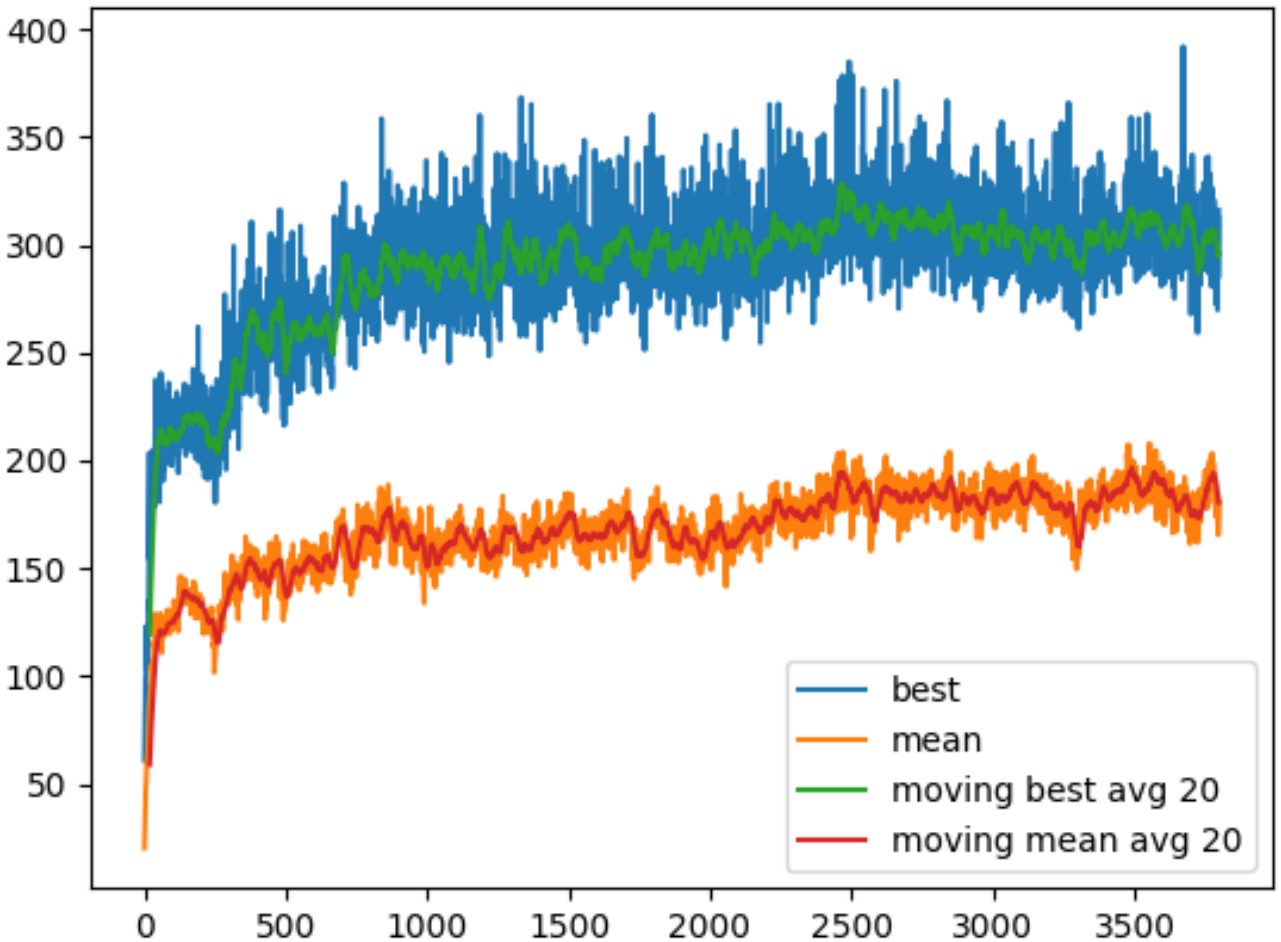
400
350
300
250
200
150
100
50
0
500
1000
1500
2000
2500
3000
3500
best
mean
moving best avg 20
moving mean avg 20

2048 LM-MA-ES

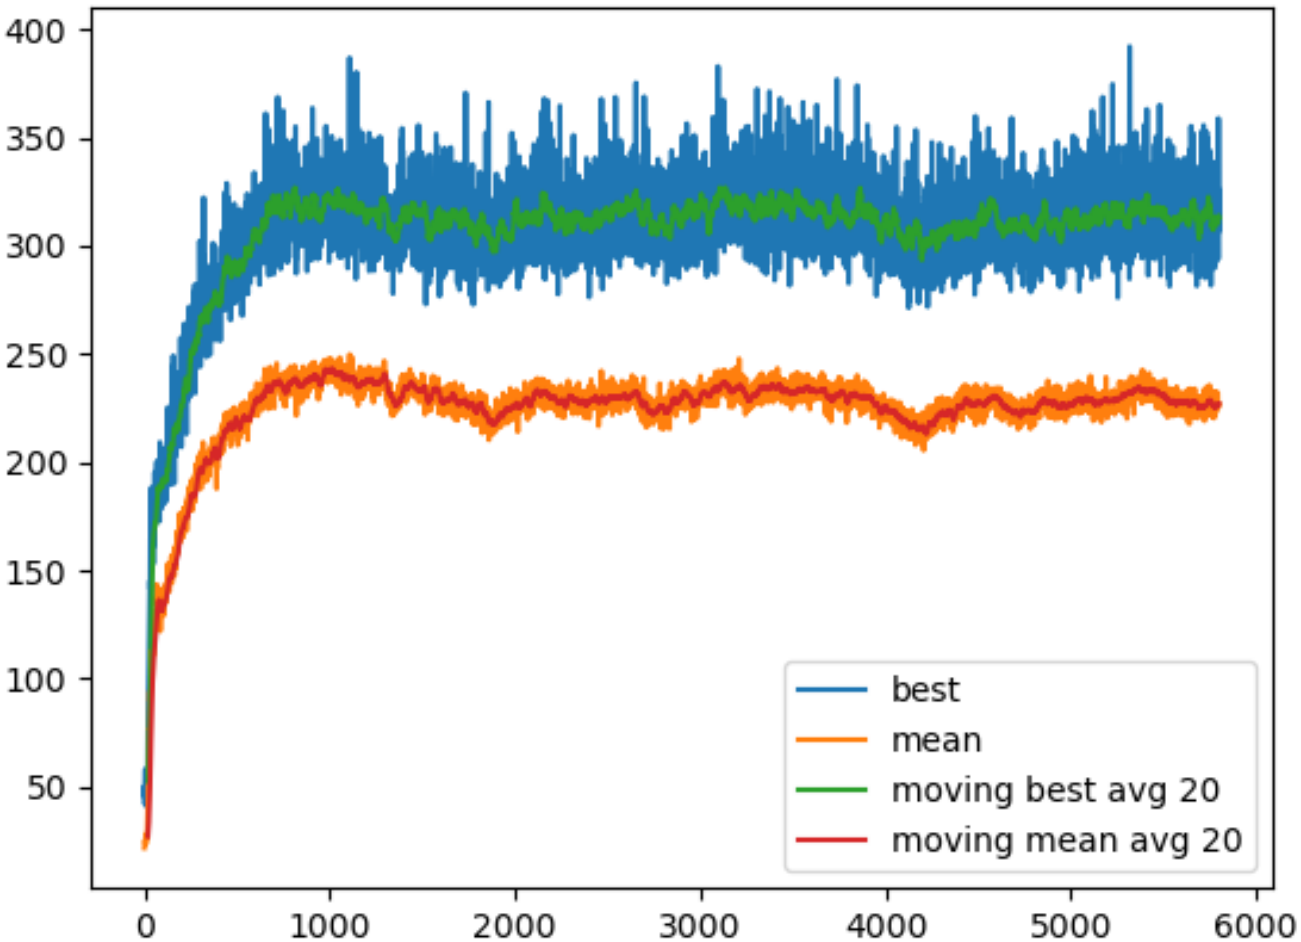
400
350
300
250
200
150
100
50
0
1000
2000
3000
4000
5000
6000
best
mean
moving best avg 20
moving mean avg 20